

PREDIKSI RISIKO PENYAKIT JANTUNG

K-Nearest Neighbors, Naive Bayes,
SVM dan Decision Tree
dengan GridSearchCV (10-Fold CV)

Muhammad Syafiq Al Fajri
NIM: A11.2024.15698
Mata Kuliah Machine Learning
Universitas Dian Nuswantoro
2025 / 2026

Agenda Presentasi

1. Pendahuluan dan Latar Belakang
2. Dataset dan Data Dictionary
3. Audit Data dan Preprocessing Pipeline
4. Desain Eksperimen (Model dan GridSearchCV)
5. Hasil Eksperimen - Tabel Perbandingan Semua Model
6. Model Terbaik (KNN Tuned) dan Error Analysis
7. Desain Aplikasi Web (Streamlit dan Gradio)
8. Kesimpulan dan Rekomendasi

PERMASALAHAN

12,9% kematian Indonesia disebabkan penyakit jantung koroner (SRS 2014)

Diagnosis sering terlambat - baru terdeteksi saat stadium lanjut

Analisis manual: lambat dan rentan terhadap human error

Belum ada sistem prediksi dini yang objektif berbasis data klinis

SOLUSI YANG DIAJUKAN

Sistem klasifikasi ML untuk prediksi risiko penyakit jantung secara dini

Pipeline bebas data leakage dengan 5 tahap preprocessing terstandar

Perbandingan 4 algoritma: KNN, Naive Bayes, SVM, Decision Tree

Optimasi GridSearchCV + deployment aplikasi web Streamlit/Gradio

TUJUAN PROJECT

- Bangun pipeline ML end-to-end bebas data leakage
- Hyperparameter tuning berbasis Recall (prioritas medis)
- Perbandingan sistematis KNN, NB, SVM, DT
- Deployment aplikasi web interaktif


Sumber Dataset

Nama	: Heart Disease Dataset
Sumber	: Mendeley Data
DOI	: 10.17632/jtwbww4z9k.1
Lisensi	: CC BY 4.0
Baris	: 1.190 -> 918 (setelah cleaning)
Fitur	: 11 fitur + 1 target
Target 0	: Sehat (44.7%)
Target 1	: Sakit/Heart Disease (55.3%)

11 Fitur Input

age	- Usia pasien (tahun)
sex	- Jenis kelamin (0=P, 1=L)
chest pain type	- Tipe nyeri dada (1-4)
resting bp s	- Tekanan darah istirahat
cholesterol	- Kolesterol total (mg/dL)
fasting blood sugar	- Gula darah puasa (0/1)
resting ecg	- Hasil EKG istirahat (0-2)
max heart rate	- Detak jantung maks (bpm)
exercise angina	- Angina saat olahraga (0/1)
oldpeak	- Depresi segmen ST (mm)
ST slope	- Slope segmen ST (1-3)

PIPELINE PREPROCESSING (Anti Data Leakage)



Model Baseline dan Parameter Awal

Model	Parameter Default	Alasan Pemilihan	Setelah Tuning
KNN	n_neighbors=5, euclidean	k=5 standar literatur	n_neighbors=9, manhattan, uniform
GaussianNB	var_smoothing=1e-9	Default; asumsi Gaussian	var_smoothing=3.16e-05
SVM	kernel=rbf, C=1, gamma=scale	RBF untuk data non-linear medis	C=1, gamma=auto, kernel=rbf
Decision Tree	gini, max_depth=None	Melihat overfit alami DT	entropy, max_depth=4, min_leaf=8

KONFIGURASI GRIDSEARCHCV (10-Fold Stratified CV, scoring=recall)

Grid KNN	: n_neighbors=[3,6,7,9], weights=[uniform,distance], metric=[euclidean,manhattan]	Grid NB	: var_smoothing = np.logspace(-12, 0, 25)
Grid SVM	: C=[0.1,1,10], kernel=[rbf,linear], gamma=[scale,auto]	Grid DT	: criterion=[gini,entropy], max_depth=[3,4,5,6,None], min_samples_split=[2,5,10,20]

METRIK EVALUASI YANG DIGUNAKAN

Accuracy	Balanced Acc	Recall (UTAMA)	Precision	F1-Score	AUC-ROC	Confusion Matrix
----------	--------------	----------------	-----------	----------	---------	------------------

HASIL EKSPERIMEN - PERBANDINGAN SEMUA MODEL (DATA AKTUAL)

Model	Acc Train	Acc Test	Bal Acc	Recall	Precision	F1	AUC-ROC	Overfit?
KNN Tuned [BEST]	0.8610	0.8696	0.8632	0.9216	0.8545	0.8868	0.9231	Tidak
KNN Baseline	0.8733	0.8641	0.8595	0.9020	0.8598	0.8804	0.9173	Tidak
NB Tuned	0.8406	0.8587	0.8522	0.9118	0.8455	0.8774	0.8953	Tidak
GaussianNB	0.8406	0.8587	0.8522	0.9118	0.8455	0.8774	0.8953	Tidak
SVM Tuned	0.8747	0.8587	0.8451	0.9706	0.8115	0.8839	0.9429	Tidak
SVM Baseline	0.8965	0.8587	0.8451	0.9706	0.8115	0.8839	0.9360	Tidak
DT Tuned	0.8610	0.6467	0.6108	0.9412	0.6194	0.7471	0.7431	Tidak
DT Baseline	1.0000	0.7065	0.6923	0.8235	0.7000	0.7568	0.6923	YA!
Dummy Baseline	0.5531	0.5543	0.5000	1.0000	0.5543	0.7133	0.5000	Tidak

KNN Tuned: n_neighbors=9, weights=uniform, metric=manhattan | SVM Tuned: C=1, gamma=auto, kernel=rbf | DT Tuned: entropy, max_depth=4, min_leaf=8 | NB Tuned: var_smoothing=3.16e-05

KEY INSIGHTS

- KNN Tuned: Acc Test TERTINGGI (0.8696) + Recall=0.9216 + F1=0.8868 + tidak overfit -> TERBAIK
- SVM Tuned: Recall lebih tinggi (0.9706) tapi Acc Test lebih rendah + FP lebih banyak (23 vs 16)
- DT Baseline: OVERFIT PARAH (Acc Train=1.00 vs Test=0.71) -> tidak layak dipakai
- DT Tuned: Overfit teratasi tapi Acc Test sangat rendah (0.65) -> DT tidak cocok dataset ini

MODEL TERBAIK: KNN TUNED - ANALISIS DETAIL

Parameter Terpilih: n_neighbors=9 | weights=uniform | metric=manhattan

0.8696	0.9216	0.8545	0.8868	0.9231	0.8632
Acc Test	Recall	Precision	F1-Score	AUC-ROC	Bal Acc

Confusion Matrix (test set: 184 sampel)

	Pred: Sehat	Pred: Sakit
Aktual Sehat	TN = 66	FP = 16
Aktual Sakit	FN = 8	TP = 94

Interpretasi Klinis

TP=94	Pasien sakit terdeteksi benar
TN=66	Pasien sehat terdeteksi benar
FP=16	Sehat diprediksi sakit (over-diagnosis)
FN=8	Sakit diprediksi sehat -> KRITIS!

MENGAPA KNN TUNED DIPILIH?

- Acc Test TERTINGGI (0.8696) - generalisasi terbaik ke data baru yang belum dilihat
- Recall tinggi (0.9216) - hanya 8 dari 102 pasien sakit yang terlewat (FN=8)
- F1-Score TERTINGGI (0.8868) - keseimbangan Precision-Recall paling optimal
- Gap overfitting minimal (0.0086) - model stabil dan tidak menghafal data training

Arsitektur Sistem

app_streamlit.py

Frontend Streamlit
11 input field pasien

app_gradio.py

Frontend Gradio
Alternatif UI Blocks

src/predict.py

Pipeline Inference
Preprocess+Scale+Predict

models/*.joblib

KNN model + Scaler
best_heart_disease_model

pipeline_meta.json

Metadata Pipeline
median, IQR, kolom urutan

Alur Inference Pipeline

Input

User isi 11 fitur
melalui UI web

↓

Preprocess

Imputasi 0->median
Capping IQR | OHE

↓

Scale

StandardScaler.transform
(scaler dari training)

↓

Predict

KNN predict_proba
Threshold = 0.35

↓

Output

Label + Probabilitas
+ Progress bar risiko

CARA MENJALANKAN

Install \$ pip install -r requirements.txt

Streamlit \$ streamlit run app_streamlit.py -> http://localhost:8501

Gradio \$ python app_gradio.py -> http://localhost:7860

KESIMPULAN

Pipeline ML bebas
data leakage berhasil

KNN Tuned dipilih
sebagai model terbaik

Acc=87%, Recall=92%
F1=89%, AUC=92%

Streamlit/Gradio
berhasil dideploy

Keterbatasan

- Dataset internasional - belum representatif populasi Indonesia
- Recall 92.16% -> masih ~8% pasien sakit yang terlewat (FN=8)
- DT sangat tidak cocok untuk dataset ini (Acc Test tuned = 64.67%)
- Aplikasi belum terintegrasi dengan sistem EMR rumah sakit

Rekomendasi Pengembangan

- Fine-tuning dengan data penyakit jantung dari RS Indonesia
- Eksplorasi Random Forest/XGBoost untuk meningkatkan Recall
- Implementasikan SHAP values untuk explainability ke klinisi
- Integrasi dengan sistem EMR untuk workflow klinis seamless
- Tambahkan biomarker troponin dan BNP yang lebih prediktif

Terima Kasih

Muhammad Syafiq Al Fajri | A11.2024.15698 | Universitas Dian Nuswantoro