

Implementasi Perbandingan Model Klasifikasi KNN, Naïve Bayes Decision Tree, SVM untuk Deteksi Dini Penyakit Jantung dengan Pendekatan Machine Learning.

Diajukan Untuk Memenuhi UTS Mata Kuliah Pembelajaran Mesin

Dosen Pengampu : Junta Zeniarja M.Kom



Disusun oleh :

Nama : Muhammad Syafiq Al Fajri

NIM : A11.2024.15698

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO**

1. ANALISIS MASALAH KLINIS TERKAIT PENYAKIT JANTUNG DAN SOLUSI KOMPUTASIONAL KRITIS

Penyakit Kardiovaskular (CVDs) atau penyakit jantung tetap bertengger sebagai salah satu ancaman kesehatan paling mematikan secara global dan nasional. Berdasarkan data berskala global dari World Health Organization (WHO), penyakit jantung menyumbang sekitar 32% dari seluruh total angka kematian di dunia setiap tahunnya. Di Indonesia, urgensi penanganan kondisi ini terefleksi dalam data survei Sample Registration System (SRS) tahun 2014, yang membuktikan bahwa sebesar 12,9% tingkat kematian nasional disebabkan secara langsung oleh penyakit jantung koroner. Secara spasial, tingkat kejadian jantung koroner tercatat berada pada manifestasi prevalensi sebesar 1,5% dalam lingkup populasi Indonesia secara agregat, serta mencapai persentase 1,6% secara spesifik di wilayah geografis Provinsi Jawa Barat.

Tingginya tingkat morbiditas serta mortalitas yang dipicu oleh penyakit jantung ini disebabkan oleh interaksi multifaktorial, yang terbagi ke dalam determinan internal dan eksternal. Faktor internal mencakup kecenderungan genetik (hereditas), pola makan tidak sehat, gaya hidup sedentari, aktivitas harian dengan tingkat stres psikologis tinggi, gangguan kesehatan mental, serta kondisi komorbid sistemik seperti hipertensi kronis. Di sisi lain, faktor eksternal disokong oleh paparan lingkungan urban yang kurang sehat serta minimnya dukungan psikologis dari pihak keluarga terdekat. Kombinasi akumulatif dari variabel-variabel multi-dimensi ini menempatkan individu pada spektrum risiko kardiovaskular yang progresif.

Tantangan paling krusial dalam manajemen klinis penyakit jantung terletak pada keterlambatan diagnosis awal secara masif. Penyakit ini kerap kali bersifat asimtomatik pada fase awal, sehingga baru terdeteksi ketika kondisi pasien telah mencapai stadium lanjut atau saat pasien mengalami serangan fungsional akut seperti infark miokard. Selama ini, pemetaan risiko pasien dalam institusi medis dilakukan secara konvensional dengan menganalisis puluhan variabel parameter kesehatan klinis serta anamnesis gaya hidup pasien secara manual. Proses penelaahan manual oleh kardiolog ini membutuhkan alokasi waktu yang signifikan, bersifat subjektif, serta rentan terhadap risiko misinterpretasi atau misdiagnosis harian di tengah tingginya beban kerja klinis rumah sakit.

Guna mengatasi kesenjangan operasional tersebut, proyek riset ini merumuskan solusi berbasis data sains (Data Science) melalui pengembangan sistem komputasi pintar berlandaskan kecerdasan buatan (Artificial Intelligence). Dengan memanfaatkan paradigma Machine Learning, model dilatih untuk memetakan risiko probabilitas pasien terjangkit penyakit jantung secara dini, objektif, cepat, serta presisi akurasi tinggi berdasarkan rekam jejak historis parameter klinis pasien. Implementasi praktis dari teknologi komputasi ini diproyeksikan berperan sebagai Clinical Decision Support System (CDSS). Pasien yang diklasifikasikan oleh sistem masuk ke dalam kategori "Sakit Jantung" dapat segera diberikan intervensi penanganan medis preventif, manajemen farmakoterapi, atau modifikasi diet ketat secara personal jauh sebelum penyakit bermanifestasi menjadi kondisi akut yang fatal.

2. JUSTIFIKASI METODOLOGIS TARGET KLASIFIKASI DALAM KERANGKA KERJA SUPERVISED LEARNING

Dalam rekayasa data dan pemodelan prediktif ini, target keluaran didefinisikan secara tegas sebagai variabel kategoris biner (diskrit), yang merepresentasikan status patologis dari kondisi kesehatan jantung pasien. Eksperimen ini menetapkan dua kelas fungsional, yaitu Kelas "0" yang melambangkan kondisi pasien "Sehat" (Absence of Heart Disease) dan Kelas "1" yang melambangkan pasien dalam kondisi "Sakit Jantung" (Presence of Heart Disease). Penentuan karakteristik luaran yang bersifat diskrit kategorikal ini mendasari keputusan ilmiah mengapa proyek riset ini wajib diselesaikan menggunakan pendekatan pembelajaran terawasi tipe klasifikasi (Supervised Classification).

Secara teoretis, arsitektur penyelesaian ini dikelompokkan ke dalam Supervised Learning karena proses induksi algoritma sangat bergantung pada ketersediaan dataset historis yang telah terlabeli secara valid (labeled data). Setiap baris data rekam medis pasien di dalam set pelatihan bertindak sebagai pasokan pasangan input-output yang diketahui jawabannya. Model mempelajari fungsi pemetaan matematika antara vektor fitur klinis (seperti level kolesterol, tekanan darah, dan usia) dengan label target riil yang melekat padanya, sehingga model mampu mengekstrak pola batas keputusan (decision boundaries) yang membedakan kedua kelompok tersebut.

Kasus pemodelan risiko medis ini secara metodologis tidak dapat diselesaikan melalui algoritma Regresi ataupun Klastering (Clustering). Pendekatan Regresi mutlak ditolak lantaran output fungsional dari algoritma regresi dirancang untuk memprediksi nilai bilangan kontinu (skalar numerik) tak terbatas, contohnya estimasi nilai umur fungsional organ atau pengukuran nilai tekanan darah. Sementara itu, kebutuhan mendesak pada skenario klinis ini adalah keputusan penegasan kelas biner yang tegas untuk menentukan alur penanganan medis pasien secara dikotomis. Di sisi lain, algoritma Klastering juga tidak relevan karena klastering beroperasi di bawah payung pembelajaran tak terawasi (Unsupervised Learning) yang menganalisis dataset mentah tanpa label target bawaan untuk mencari pengelompokan alami mandiri berdasarkan metrik jarak kemiripan. Dikarenakan proyek ini telah memiliki basis data dengan label diagnosis kebenaran mutlak (ground-truth labels) yang diverifikasi oleh pemeriksaan klinis ahli, maka penggunaan klasifikasi terawasi menjadi satu-satunya jalur pemodelan yang valid, efisien, dan objektif.

3. MINI-REVIEW KOMPREHENSIF PAPER UTAMA (REFERENSI KONTEMPORER)

Sebagai pijakan akademis yang kokoh dalam menjamin validitas metodologi riset, proyek ini melakukan penelaahan mendalam terhadap literatur ilmiah utama bertaraf internasional yang diterbitkan pada jurnal bereputasi tinggi Q1 dari Amine et al. (2024) yang berjudul "Early heart disease prediction using feature engineering and machine learning algorithms" di jurnal Heliyon (Cell Press).

Komponen	Detail / Isi
Penulis	Amine et al.
Tahun	2024
Jurnal / Judul	Heliyon (Cell Press).

	"Early heart disease prediction using feature engineering and machine learning algorithms"
DOI	10.1016/j.heliyon.2024.e38731
Metode	Komparasi 6 model (LR, KNN, AdaBoost, DT, RF, SVM) + Z-Score + Hyperparameter Tuning via Pipeline + 10-Fold CV.
Dataset	Cleveland Dataset (14 fitur inti, 287 sampel bersih) & Statlog Dataset (270 sampel).
Metrik	Akurasi (ACC), Presisi (PRS), Recall (SS), F1-Score, AUC-ROC.
Hasil Utama	SVM Linear meraih performa tertinggi: Akurasi 92,00% (Cleveland) dan 91,18% (Statlog). Nilai Recall mencapai 100%.
Relevansi Proyek	Menjadi cetak biru (blueprint) pipa data, validasi parameter (C=2, kernel=linear), dan skema optimasi untuk implementasi Google Colab.

4. DEKONSTRUKSI MATEMATIS DAN METODE OPTIMASI

Berdasarkan landasan teoretis dari literatur Amine et al. (2024), performa maksimal sebuah model klasifikasi tidak dapat diperoleh semata-mata dari konfigurasi bawaan algoritma. Dibutuhkan serangkaian intervensi rekayasa data dan optimasi algoritmik sistematis berikut:

A. Pengondisian Data Skala Klinis (Feature Engineering & Scaling) Dataset medis mengandung variabel dengan rentang nilai yang sangat timpang. Kondisi ketimpangan skala ini akan mendegradasi keakuratan algoritma berbasis komputasi jarak geometri seperti KNN dan SVM, karena fitur berskala besar akan mendominasi perhitungan bobot matematika secara bias. Oleh karena itu, diterapkan normalisasi standar menggunakan StandardScaler berbasis transformasi skor Z (Z-score normalization). Secara matematis, setiap titik data mentah (x) dikonversi melalui persamaan struktural berikut:

$$Z\text{-score} = (x - \mu) / \sigma$$

Pencilan ekstrim dieliminasi menggunakan ambang batas nilai absolut skor Z, yang berhasil mereduksi total ukuran sampel Cleveland dari 303 rekaman menjadi 287 rekaman data bersih bebas noise fungsional.

B. Penanganan Ketidakseimbangan Kelas Data Medis (Imbalance Handling via SMOTE)

Distribusi data diagnosis riil kerap kali mengalami fenomena ketidakseimbangan kelas. Dampak buruk dari kondisi ini adalah model rentan mengalami bias kognitif sistemik, yaitu cenderung mengklasifikasikan kasus baru ke dalam kelompok mayoritas demi mengejar nilai akurasi global yang semu, namun gagal total dalam mendeteksi kelompok minoritas (False Negative). Guna memitigasi risiko tersebut, proyek ini mengintegrasikan metode optimasi Synthetic Minority Over-sampling Technique (SMOTE) yang bekerja di tingkat ruang fitur dengan cara menciptakan instansi data sintetis baru dari kelas minoritas secara matematis lewat penarikan interpolasi garis lurus di antara k-tetangga terdekat kelas minoritas.

C. Validasi Silang Berstrata 10-Fold (10-Fold Stratified Cross-Validation)

Untuk menghindari jebakan optimisme semu akibat pembagian data latih-uji tunggal (train-test split dependency) dan mendeteksi gejala overfitting, model dievaluasi secara ketat menggunakan metode 10-Fold Stratified Cross-Validation dengan Interval Kepercayaan 95%.

Sifat "Stratified" (berstrata) menjamin bahwa rasio persentase distribusi antara kelas pasien "Sehat" dan "Sakit" pada setiap fold tetap terjaga persis sama dengan proporsi pada dataset asli keseluruhan. Interval kepercayaan yang diperoleh berkisar antara 86,59% hingga 92,17% pada dataset Cleveland, menegaskan stabilitas generalisasi model.

D. Pencarian Hyperparameter Optimal Menggunakan GridSearchCV

Guna mengoptimasi parameter secara objektif, diaplikasikan metode pencarian kisi tervalidasi (GridSearchCV). Melalui teknik pemipaan (pipelining), dijalankan penelaahan terhadap seluruh kombinasi parameter potensial. Formulasi matematis algoritma hasil tuning terbaik didekonstruksi sebagai berikut:

- Logistic Regression (LR): Memodelkan probabilitas (p) logaritmis menggunakan fungsi logit dan fungsi sigmoid fungsional:

$$\ln(p / (1 - p)) = b_0 + b_1 X_1$$

Konfigurasi optimal: solver='liblinear', C=1.0, tol=0.01.

- Support Vector Machine (SVM): Memproyeksikan data klinis ke ruang dimensi tinggi untuk mencari bidang pemisah linier optimal berjarak maksimal (Maximum Margin Hyperplane). Persamaan matematik dari hyperplane H dinyatakan sebagai:

$$H : w^T \phi(x) + b = 0$$

Metrik jarak Euclidean dari vektor bobot $\|w\|_2$ didefinisikan lewat formula akar kuadrat kuadratis:

$$\|w\|_2 = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

Konfigurasi optimal: C=2, kernel='linear', multi-kelas 'one-vs-rest'. Model ini meraih Akurasi tertinggi sebesar 92,00% dengan AUC 0,91.

- Adaptive Boosting (AdaBoost): Algoritma ensemble learning sekuesial yang membangun pengklasifikasi kuat akhir melalui kombinasi linier terbobot dari kumpulan T hipotesis pembelajar lemah:

$$f(x) = \sum_{t=1}^T \alpha_t h_t(x)$$

Bobot penentu dari masing-masing pembelajar lemah (α_t) dihitung berdasarkan tingkat galat tertimbang (e_t):

$$\alpha_t = \frac{1}{2} \ln((1 - e_t) / e_t)$$

Konfigurasi optimal: algoritma='SAMME.R', n_estimators=1100, learning_rate=0.01.

Decision Tree (DT) & Random Forest (RF): Pemisahan simpul cabang pohon didasarkan pada metrik ketidakmurnian Gini Impurity dan Entropi Informasi:

$$\text{Gini} = 1 - \sum_{i=1}^L (p_i)^2 \quad | \quad \text{Entropy} = - \sum p_i \log_2(p_i)$$

Konfigurasi optimal RF: 500 pohon independen, kriteria 'gini', kedalaman maksimal dibatasi pada level 8.

- K-Nearest Neighbors (KNN): Mengukur kedekatan geometri data baru menggunakan metrik jarak khusus Canberra Distance untuk data biomedis berdimensi jamak:

$$D(x', c_j) = (1/p) \sum_{i=1}^p (|x'_i - c_{ji}|) / (|x'_i| + |c_{ji}|)$$

Konfigurasi optimal: Nilai k tetangga ditentukan secara presisi sebanyak 23 tetangga berbobot seragam ('uniform') berdasarkan minimalisasi nilai galat Mean Squared Error (MSE).

E. Evaluasi Metrik Berorientasi Klinis (Clinical Evaluation Framework)

Pemilihan model terbaik didasarkan pada metrik evaluasi komprehensif turunan dari matriks kekacauan (confusion matrix) melalui formulasi matematika fungsional berikut:

$$\text{Accuracy (ACC)} = (TP + TN) / (TP + FP + FN + TN)$$

$$\text{Precision (PRS)} = TP / (TP + FP) |$$

$$\text{Recall / Sensitivity (SS)} = TP / (TP + FN) \quad \text{F1-Score} = 2TP / (2TP + FP + FN)$$

Berdasarkan matriks pengujian data tak terlihat, model SVM berhasil menduduki performa puncak dengan capaian Akurasi 92,00%, Presisi 86,96%, dan tingkat Sensitivitas/Recall sempurna mencapai 100% (FN = 0) untuk mendeteksi pasien kategori Sakit, menjadikannya sistem pendukung keputusan klinis yang paling aman dari risiko luput diagnosis.

5. PROTOKOL KEPATUHAN ETIKA DATA DAN BATASAN PRIVASI PASIEN KONTEMPORER

Pengembangan sistem kecerdasan buatan dalam domain kesehatan wajib tunduk pada standar regulasi etika profesi melalui lima pilar protokol kepatuhan data:

- 1) Anonimisasi Data Secara Absolut: Seluruh identitas personal pasien yang bersifat Personally Identifiable Information (PII) seperti Nama, NIK, dan Alamat Rumah spesifik telah dihapus secara permanen sebelum siklus pemrosesan data dimulai.
- 2) Masking Identitas Tingkat Lanjut: Fitur yang bersifat semi-identitas (seperti kode pos wilayah atau ID instansi rumah sakit asal perujuk) ditransformasi menggunakan teknik data masking dan enkripsi hash satu arah untuk mencegah re-identifikasi.
- 3) Pemberlakuan Batasan Penggunaan Prediksi: Pemanfaatan model komputasi ini dikunci secara hukum hanya untuk tujuan riset akademis dan sarana simulasi edukatif dalam lingkungan Universitas Dian Nuswantoro, serta dilarang keras disalahgunakan untuk kepentingan komersial sepihak seperti dasar penetapan premi asuransi kesehatan.
- 4) Doktrin Human-in-the-Loop (Bukan Keputusan Tunggal): Model kecerdasan buatan ini berstatus sebagai Decision Support System (Sistem Pendukung Keputusan), bukan bertindak • 1. 2. 3. 4. sebagai Decision Maker tunggal. Keputusan akhir diagnosis dan tindakan klinis wajib berada sepenuhnya di tangan tenaga medis profesional berlisensi (Dokter Kardiolog).
- 5) Prinsip Integritas Dan Anti-Diskriminasi: Hasil prediksi dari model dilarang disalahgunakan oleh pihak institusi kesehatan untuk melakukan tindakan diskriminasi pelayanan medis atau pembatasan akses fasilitas kesehatan berdasarkan profil riwayat genetika maupun faktor demografis pasien.

6. KESIMPULAN DAN PERSPEKTIF PENGEMBANGAN MASA DEPAN

Riset komparatif berlandaskan metodologi mutakhir Amine et al. (2024) membuktikan bahwa algoritma Support Vector Machine (SVM) berbasis kernel linier menjadi model paling

superior dengan tingkat akurasi 92,00% pada Cleveland dataset dan stabilitas generalisasi sebesar 91,18% pada validation phase menggunakan Statlog Heart Dataset. Perspektif pengembangan ke depan akan difokuskan untuk mengintegrasikan multi-sumber data baru (multimodal data fusion) yang menggabungkan data gaya hidup real-time dari perangkat IoT (wearable devices) serta ekstraksi fitur tekstur radiomiks pencitraan medis hasil pemindaian Cardiac CT-Scan guna menekan angka fatalitas penyakit jantung di Indonesia.